



《模式识别》

第一章 课程简介与预备知识

马锦华

<https://cse.sysu.edu.cn/teacher/MaJinhua>

SUN YAT-SEN University



声明：该PPT只供非商业使用，也不可视为任何出版物。由于历史原因，许多图片尚没有标注出处，如果你知道图片的出处，欢迎告诉我们 majh8@mail.sysu.edu.cn.

授课老师信息

□ 授课老师：马锦华 副教授/博导

研究方向：模式识别、计算机视觉、视频监控、生成模型、医学图像处理


- 近年在IEEE TPAMI、IJCV、IEEE TIP等SCI期刊及ICCV、CVPR、AAAI等国际会议累计发表学术论文70余篇，包括中科院一区/CCF A类论文30余篇，ESI高被引论文1篇，申请及授权专利10余项；主持国自然等科研基金10余项

- 中山大学“百人计划”引进人才
- 美国约翰霍普金斯大学（世界前20）博士后
- SCI国际期刊JEL副编辑
- IEEE TPAMI、IEEE TIP等SCI国际期刊审稿人
- ICCV、CVPR、AAAI等国际会议程序委员
- 中国图形图像学会(CSIG)机器视觉专委会委员
- 广州市人工智能学会理事
- 广东省自然科学奖一等奖

生成模型



医学图像处理



视频分析

Welcome!



- ❑ 课件链接: <https://pan.baidu.com/s/1uUo9M9oYARCNEPj8u1e15w>
 - 提取码: s3cc
- ❑ 助教
 - 樊耀舞、杨庆城、倪嘉骏
- ❑ 推荐书目
 - 模式识别, 吴建鑫
 - Pattern Classification, 2nd ed., Stork, Hart, and Duda
 - Pattern Recognition and Machine Learning, Bishop
 - 机器学习, 周志华
 - 神经网络与深度学习, 邱锡鹏
 - Stanford Courses CS131 and CS231N
 - Computer Vision: A Modern Approach, Forsyth & Ponce
 - Computer Vision: Algorithms and Applications, 2nd ed., Szeliski
- ❑ 成绩评定: 期末大作业 (60%)、平时作业 (30%) 和课堂表现 (30%)





课程目录（暂定）

❑	第一章	课程简介与预备知识	6学时
❑	第二章	特征提取与表示	6学时
❑	第三章	主成分分析	3学时
❑	第四章	归一化、判别分析、人脸识别	3学时
❑	第五章	EM算法与聚类	3学时
❑	第六章	贝叶斯决策理论	3学时
❑	第七章	线性分类器与感知机	3学时
❑	第八章	支持向量机	3学时
❑	第九章	神经网络、正则项和优化方法	3学时
❑	第十章	卷积神经网络及经典框架	3学时
❑	第十一章	循环神经网络	3学时
❑	第十二章	Transformer	3学时
❑	第十三章	自监督与半监督学习	3学时
❑	第十四章	开放世界模式识别	6学时



模式识别22级-马老师

此群是企业内部群聊，仅企业成员可扫码加入



该二维码7天内(3月4日前)有效



第一部分：模式识别简介

什么是模式识别?

- ❑ “Pattern recognition is the **automated** recognition of **patterns** and **regularities** in **data**.”
 - Wiki (2022-02-18): Pattern recognition
- ❑ “Pattern recognition (psychology), identification of faces, objects, words, melodies, etc.”
 - Wiki (2022-02-18): Pattern recognition (disambiguation)
- ❑ 模式识别 (Pattern Recognition)
 - 对模式（规律）的区分和认识，把对象根据其特征归到若干类别中适当的类
 - 亦称作模式分类 (Pattern **Classification**)
 - 再认识: re-cognition



什么是模式识别？

□ ChatGPT

请定义什么是模式识别

模式识别 (Pattern Recognition) 是指通过观察和分析数据中的特征，识别出其中的规律或结构的过程。这个过程通常包括从大量信息中提取有意义的模式、对这些模式进行分类和预测。模式识别在人工智能、机器学习、计算机视觉、语音识别、自然语言处理等多个领域都有广泛应用。

简单来说，模式识别就是让计算机能够像人类一样，识别、理解并作出反应。比如，我们可以通过分析图片中的特征来识别物体，或者通过分析声音的特征来识别语音。

模式识别的常见步骤包括：

1. **数据采集**：获取原始数据（如图片、声音、文本等）。
2. **特征提取**：从数据中提取出有意义的特征，减少数据的复杂性。
3. **分类或回归**：根据提取的特征进行分类（如物体识别、情感分析等）或预测（如股市预测）。
4. **评估和调整**：通过评估模型的准确性，调整算法参数，提升识别效果。

这种技术在很多实际应用中起到了至关重要的作用，如面部识别、指纹识别、自动驾驶等。



什么是模式识别?

□ DeepSeek

模式识别的定义与应用领域



☞ 已深度思考 (用时 41 秒) ▾

模式识别是一个跨学科领域，主要研究如何通过计算机系统自动识别数据中的规律或结构，并利用这些信息进行分类、预测或决策。其核心在于从复杂数据中提取有效特征，并基于这些特征构建模型以实现未知数据的处理。以下是模式识别的关键要素：

1. 定义

模式识别是指通过数学和计算方法，让机器能够自动检测、分析和分类数据中的重复规律或结构。这些模式可以是数值、符号、图像、声音等形式，涵盖统计特征、形状、序列或语法规则等。

2. 核心步骤

- **数据采集**：获取原始数据（如传感器输入、图像、文本等）。
- **预处理**：清洗数据以去除噪声，并进行标准化或归一化。
- **特征提取**：从数据中选取关键特征（如边缘检测、频谱分析）。
- **模型构建**：使用算法（如分类器、聚类方法）建立识别模式。
- **决策与评估**：对结果进行分类或预测，并通过准确率等指标验证模型性能。

3. 方法分类

- **统计方法**：基于概率模型和统计分析（如贝叶斯决策、支持向量机）。

模式识别的特征

❑ 两重含义

- 模式识别的任务：对数据中规律和模式的自动识别
- 模式识别的方法，尤指统计模式识别方法，是完成模式识别任务的一类方法

❑ 输入：样本（Sample）

- Image, video, voice, text, ...

❑ 输出：预测的类别（Predicted Label）

- Person identity, object class, words, topic, ...

❑ 输入转换到输出：

- 由计算机系统完成 (automatic, algorithm, ...)
- 是一个困难但有趣的过程 (knowledge discovery)


有监督与无监督模式识别

- ❑ 有监督模式识别 (Supervised Pattern Recognition)
 - 目标类别确定，训练样本类别已知，建立分类器对未来未知样本分类
- ❑ 无监督模式识别 (Unsupervised Pattern Recognition)
 - 目标类别未知，发现和划分未知样本中可能存在的类

模式识别举例：Autopilot



- ✓ 输入?
- ✓ 输出?
- ✓ 困难?




视频来源: <https://www.tesla.cn/autopilot>

模式识别举例：Kinect



- ✓ 输入？
- ✓ 输出？
- ✓ 困难？




视频来源：<https://www.youtube.com/watch?v=oyjNqksc-m8>



模式识别举例：Siri

- ✓ 输入？
- ✓ 输出？
- ✓ 困难？



视频来源：<https://www.bilibili.com/video/BV1Ss411x7Wb?p=1&t=24.4>

(虚拟例子) 性别识别：特征

- ❑ 选取什么**数据**来判别一个人的性别？
 - 长相？
 - 喉结？
 - 身高？
 - 体重？
 - 声音？
 - 行为？
 - ...
- ❑ 被**使用**的数据或从原始输入数据(raw input data)中提取(extract)的数据称为**特征**(feature)
 - 为什么要选取、提取、或者**学习**特征？

(虚拟例子) 性别识别：评估

- ❑ 怎么知道模式识别的结果好坏？
 - 评估或评价(evaluate)
 - 通常是把模式识别系统的输出(称为**预测**, prediction)与**真实值**(groundtruth)进行**比较**
- ❑ 真实值从哪里来？
 - 女性的性染色体 $XX \rightarrow X$ (来自母亲) + X (来自父亲)
 - 男性的性染色体 $XY \rightarrow X$ (来自母亲) + Y (来自父亲)
- ❑ 如何进行比较？
 - 以后会讲，现在先想一想？


(虚拟例子) 性别识别：转换

- ❑ 如何构建一个模式识别系统将输入转换为输出
 - 常见方法：机器学习(machine learning)
 - 从过去的经验学习(Learning from experience)
 - 训练集(training set): 已搜集的数据
 - 模型(model): 从训练集得到的规律，表现形式多样
 - 测试(prediction, testing): 将这些规律应用到新的例子以得到针对该例子的结果（模式识别的输出）
 - 测试集(testing set): 为了评估这些规律搜集的数据
 - 那么，对训练集和测试集应该有什么要求？

(虚拟例子) 性别识别：应用

- ❑ 得到输出后，有什么用？
 - 通常在更大的系统中起作用
 - Siri, Kinect, ...

- ❑ 那么，模式识别系统**要做到多好呢**？
 - 由那个“更大的系统”决定
 - 是不是只要准确率越高越好？



问题：

- ✓ 是这样吗？
 - 需要多次反馈(feedback)、尝试、修改
- ✓ 什么步骤最重要
 - ??
- ✓ 深度学习在图中什么位置？

模式识别为什么困难？

❑ 多种原因

- 语义鸿沟(semantic gap), 如 2000×1000 的图像是什么？
 - ❖ 对人的眼睛和大脑：教师、桌椅、讲台、黑板、人、...
 - ❖ 对计算机： $3 \times 2000 \times 1000 = 6,000,000$ 个数字
- 计算能力(computational power)
 - ❖ 很多算法在台式机上要数年或更长时间
 - ❖ 大数据，存储和计算都成为问题
- 数据的获取(data acquiring)
 - ❖ 很多时候数据难以获取（如医学图像medical imaging）
 - ❖ 或者虽然容易获取，但是难以标注（如网络图像的精确标注annotation）

各步骤的（实践）重要性

1. 提取特征

- o 设想一下，知道一个人的年纪，需要判别其性别？
- o 或者，知道一个人的样貌描述，需要判别其性别？

2. 数据获取

- o 设想一下，根据图像判断性别，所有训练图像都只包含男子、而不包含任何女子？
- o 或者，图像中有男有女，但是所有都标记为女？

3. 机器学习



- o 有很多理论上重要的问题，对实践效果也非常重要

模式识别vs.机器学习

- ❑ “模式识别”与“机器学习”的字面含义
 - “识别”是目标，“学习”是过程、手段
- ❑ 机器学习的含义
 - 学习机器：能自动改进完成某种任务的计算机算法或系统
 - 机器学习：研究学习机器相关理论、方法和技术的学科
- ❑ 机器学习与模式识别
 - 模式识别是最常见的机器学习任务
 - 统计模式识别方法是一类典型的机器学习方法
 - 机器学习是模式识别的重要手段
 - 二者伴随发展，没有明确的分界线

模式识别vs.计算机视觉

- ❑ 模式识别与计算机视觉(computer vision)的研究和应用有**非常多的重合**
 - 识别recognition是计算机视觉中最重要的问题之一
 - 模式识别中很大部分输入是图像或视频
- ❑ 模式识别包含很多视觉以外的问题
 - 音频、雷达、文本、...
- ❑ 计算机视觉包括很多识别以外的问题
 - 超分辨率super-resolution
 - 三维重建3D reconstruction



图片来源: <https://towardsdatascience.com/single-image-super-resolution-challenge-6f4835e5a156>

❑ Building Rome in a Day [Agarwal et al., ICCV'09]




视频来源: <http://grail.cs.washington.edu/rome/>

❑ 单张图片深度学习深度估计


- F. Liu, C. Shen, G. Lin and I. Reid, "Learning Depth from Single Monocular Images Using Deep Convolutional Neural Fields," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, no. 10, pp. 2024-2039, 2016.



Test image




Ground-truth




DCNF-FCSP



Test image




Ground-truth



DCNF-FCSP

❑ “人工智能（AI）”一词的含义

- 广义：任何由机器或程序实现的“智能”行为，“机器智能”
- 狭义：从1956年发展起来的以符号主义为主的人工智能(AI)



- 从始至终，人工智能(AI)便在充满未知的道路探索，曲折起伏，我们可将这段发展历程大致划分为5个阶段期：
 - 起步发展期：1943年—20世纪60年代
 - 反思发展期：20世纪70年代
 - 应用发展期：20世纪80年代
 - 平稳发展期：20世纪90年代—2010年
 - 蓬勃发展期：2011年至今

起步发展期：1943年—20世纪60年代

- 人工智能概念的提出后，发展出了符号主义、联结主义(神经网络)，相继取得了一批令人瞩目的研究成果，如机器定理证明、跳棋程序、人机对话等，掀起人工智能发展的第一个高潮。

01

图灵测试的提出

图灵测试由英国数学家艾伦·图灵于1950年提出，旨在判断机器是否具有智能。如果一个机器能够展现出与人类无法区分的行为，那么它就可以被视为具有智能。

02

逻辑理论的奠基

早期AI研究中，逻辑推理程序的发展始于对逻辑理论的深入探究，旨在通过形式化方法模拟人类的推理过程，为人工智能的逻辑基础奠定基石。

03

自动定理证明

在逻辑推理程序的研究初期，自动定理证明成为一大突破，通过计算机程序自动推导出数学或逻辑命题的正确性，展示了机器智能处理复杂逻辑问题的能力。

Perceptron





Nature, 1986

Learning representations by back-propagating errors

David E. Rumelhart*, Geoffrey E. Hinton†
& Ronald J. Williams*

* Institute for Cognitive Science, C-015, University of California,
San Diego, La Jolla, California 92093, USA

† Department of Computer Science, Carnegie-Mellon University,
Pittsburgh, Philadelphia 15213, USA



Mark I perceptron machine, 1957



- 人工智能发展初期的突破性进展大大提升了人们对人工智能的期望，人们开始尝试更具挑战性的任务，然而算力及理论等的匮乏使得不切实际目标的落空，人工智能的发展走入低谷。

01

经济衰退与资金紧缩

在经济衰退期间，许多企业与政府机构面临预算削减的压力，这直接影响了人工智能研究的投资，导致该领域的研究资金大幅减少。

02

计算能力限制

随着AI技术的深入发展，现有的计算能力成为制约人工智能发展的瓶颈。处理复杂算法和大规模数据需要更强大的计算资源，这对硬件提出了更高的要求。

03


数据与隐私安全

高质量的数据是训练有效AI模型的关键。然而，获取大量、多样化且无偏见的数据集常常困难重重，数据隐私和安全问题也日益凸显，成为技术发展的重要障碍。


Minsky and Papert, 1969



X	Y	F(x,y)
0	0	0
0	1	1
1	0	1
1	1	0



- *Showed that Perceptrons could not learn the XOR function*
- *Caused a lot of disillusionment in the field*



- 专家系统模拟人类专家的知识和经验解决特定领域的问题，实现了人工智能从理论研究走向实际应用、从一般推理策略探讨转向运用专门知识的重大突破。而机器学习(特别是神经网络)探索不同的学习策略和各种学习方法，在大量的实际应用中也开始慢慢复苏。

01

专家系统的兴起

随着逻辑推理程序的发展，专家系统应运而生，利用规则和知识库模拟领域专家的决策过程，解决了特定领域的复杂问题，标志着AI应用的初步实现。

02

机器学习的崛起

随着计算能力的增强和大数据的出现，机器学习技术迅速发展，尤其是深度学习技术的突破，为人工智能的广泛应用奠定了基础。

03


反向传播算法的突破

反向传播算法的提出极大地推进了神经网络的发展，它通过梯度下降法优化网络权重，有效提高了神经网络的学习效率和准确性。

Neocognitron: Fukushima, 1980




- *Computational model of the visual system, directly inspired by Hubel and Wiesel's hierarchy of complex and simple cells*
- *Interleaved simple cells (convolution) and complex cells (pooling)*
- *No practical training algorithm*




Backprop: Rumelhart, Hinton, and Williams, 1986



- *Introduced backpropagation for computing gradients in neural networks*
- *Successfully trained perceptrons with multiple layers*



Convolutional Networks: LeCun et al, 1998




- *Applied backprop algorithm to a Neocognitron-like architecture*
- *Learned to recognize handwritten digits*
- *Was deployed in a commercial system by NEC, processed handwritten checks*
- *Very similar to our modern convolutional networks!*

平稳发展期：20世纪90年代—2010年




- 2000年代初，由于专家系统的项目都需要编码太多的显式规则，这降低了效率并增加了成本，人工智能研究的重心从基于知识系统转向了机器学习方向。



Support Vector Machine (SVM), 1990s

- ❑ Cortes & Vapnik (1995). "Support-vector networks". Machine Learning. 20 (3): 273–297.
- ❑ Motivation: Maximum-margin classification


Linear SVM



Support Vector Machine (SVM), 1990s




- Kernel method: Map features into high-dimensional space, (probably) linearly separable



Kernel SVM


支持向量机

- 支持向量机 (Support Vector Machine, SVM) 可以视为在感知机基础上的改进，是建立在统计学习理论的VC维理论和结构风险最小原理基础上的广义线性分类器。
- 与感知机主要差异在于：
 - 感知机目标是找到一个超平面将各样本尽可能分离正确(有无数个)，SVM目标是找到一个超平面不仅将各样本尽可能分离正确，还要使各样本离超平面距离最远(只有一个最大边距超平面)，SVM的泛化能力更强。
 - 对于线性不可分的问题，不同于感知机的增加非线性隐藏层，SVM利用核函数，本质上都是实现特征空间非线性变换，使可以被线性分类。




长短时记忆网络


- 长短时记忆网络（Long Short-Term Memory, LSTM）是一种复杂结构的循环神经网络（RNN），结构上引入了遗忘门、输入门及输出门：
 - 输入门决定当前时刻网络的输入数据有多少需要保存到单元状态，遗忘门决定上一时刻的单元状态有多少需要保留到当前时刻
 - 输出门控制当前单元状态有多少需要输出到当前的输出值。
 - 这样的结构设计可以解决长序列训练过程中的梯度消失问题。



- ❑ 随机森林 (Random Forest) 是一种集成学习方法
 - 将多个有差异的弱学习器(决策树) 并行组合, 通过建立多个的拟合较好且有差异模型去组合决策, 以优化泛化性能
 - 多样差异性可减少对某些特征噪声的依赖, 降低方差 (过拟合), 组合决策可消除些学习器间的偏差。



- ❑ 迁移学习(transfer learning)通俗来讲，就是运用已有的知识（如训练好的网络权重）来学习新的知识以适应特定目标任务
 - 核心是找到已有知识和新知识之间的相似性。



蓬勃发展期：2011年至今

- ❑ 大数据、云计算、互联网、物联网等信息技术的发展
- ❑ 大量感知数据和图形处理器等计算平台推动以深度神经网络为代表的人工智能技术飞速发展
- ❑ 大幅跨越了科学与应用之间的技术鸿沟，诸如图像分类、语音识别、知识问答、人机对弈、无人驾驶等人工智能技术实现了重大的技术突破，迎来爆发式增长的新高潮。

Durk Kingma和Max Welling提出
变分自编码器VAE；
Google的Tomas Mikolov提出
Word2Vec

2012

2013

2014

2015

2017

2022至今

Microsoft Research
的Kaiming He等人提
出残差网络ResNet



ChatGPT
Stable Diffusion
Suno AI
Sora 等

Hinton和他的学生Alex
Krizhevsky设计了AlexNet

Goodfellow及Bengio等
人提出生成对抗网络GAN

Google的Ashish Vaswani
等人提出Transformer

- ❑ 深度学习（Deeping Learning）的概念源于人工神经网络的研究，
 - 它的本质是使用多个隐藏层网络结构，通过大量的向量计算，学习数据内在信息的高阶表示。
- ❑ 深度学习三巨头LeCun、Bengio和Hinton推出的深度学习的联合综述《Deep learning》一书中指出：
 - 深度学习就是一种特征学习方法，把原始数据通过一些简单的但是非线性的模型转变成为更高层次及抽象的表达，能够强化输入数据的区分能力。
 - 通过足够多的转换的组合，非常复杂的函数也可以被学习。



“Deep Learning”

People tried to train neural networks that were deeper and deeper


Not a mainstream research topic at this time

No good dataset to work on

Bengio et al, 2007

Lee et al, 2009

Glorot and Bengio, 2010




Hinton & Salakhutdinov, Reducing the Dimensionality of Data with Neural Networks. Science 313, 504-507 (2006).

ImageNet: 2009



IMAGENET Large Scale Visual Recognition Challenge

The Image Classification Challenge:
1,000 object classes
1,431,167 images



Output:
Scale
T-shirt
Steel drum
Drumstick
Mud turtle

Deng, ..., Fei-Fei, ImageNet: A Large-Scale Hierarchical Image Database. CVPR, 2009.


Russakovsky, ..., Fei-Fei. ImageNet Large Scale Visual Recognition Challenge. IJCV, 2015.



ImageNet: 2009



IMAGENET Large Scale Visual Recognition Challenge



Deep learning becomes popular since the development of AlexNet in 2012



GPU Acceleration



	NVIDIA GeForce RTX 3090	NVIDIA GeForce RTX 4090
Architecture	Ampere	Ada
Process	Samsung 8nm	TSMC 4nm
CUDA Cores	10496	16384
RT Cores	82 (2nd Generation)	128 (3rd Generation)
Tensor Cores	328 (3rd Generation)	512 (4th Generation)
GPU Boost Clock	1695 MHz	2520 MHz
Memory	24 GB GDDR6X	24 GB GDDR6X
Memory Interface	384-bit	384-bit
Transistor Count	28.3 Billion	76.3 Billion
Connectors	3x DisplayPort 1.4a, 1x HDMI 2.1	3x DisplayPort 1.4a, 1x HDMI 2.1
Form Factor	Triple Slot	Triple Slot
Total Graphics Power (TGP)	350W	450W


<https://www.ausgamers.com/features/read/3642595>




Banned by US to be sold in China



AlexNet vs. Neocognitron: 32 years apart




Neocognitron



AlexNet




- 2012年，Hinton和他的学生Alex Krizhevsky设计的AlexNet神经网络模型在ImageNet竞赛大获全胜，这是史上第一次有模型在 ImageNet 数据集表现如此出色，并引爆了神经网络的研究热情。
- AlexNet是一个经典的CNN模型，在数据、算法及算力层面均有较大改进，创新地应用了Data Augmentation、ReLU、Dropout和LRN等方法，并使用GPU加速网络训练。




残差网络ResNet

- 残差网络的主要贡献是发现了网络不恒等变换导致的“退化现象（Degradation）”，并针对退化现象引入了“快捷连接（Shortcut connection）”，缓解了在深度神经网络中增加深度带来的梯度消失问题。




Word2Vec

- Word2Vec模型用来学习单词分布式表示
 - 因其简单高效引起了工业界和学术界极大的关注。
 - 其基本的思想是学习每个单词与邻近词的关系，从而将单词表示成低维稠密向量。通过这样的分布式表示可以学习到单词的语义信息，直观来看，语义相似的单词的距离相近。




Word2Vec网络结构示意图




Word2Vec学习到的单词在二维空间中的分布

变分自编码器

- 变分自编码器（Variational Auto-Encoder, VAE）基本思路
 - 将真实样本通过编码器网络变换成一个理想的数据分布，然后把数据分布再传递给解码器网络，构造出生成样本，模型训练学习的过程是使生成样本与真实样本足够接近。




- 生成对抗网络（Generative Adversarial Network, GAN）的设计思路
 - 由生成网络(Generator, G)和判别网络(Discriminator, D)两部分组成
 - 生成网络构成一个映射函数 $G: Z \rightarrow X$ （输入噪声 z , 输出生成的伪造数据 x ）, 判别网络D判别输入是来自真实数据还是生成网络生成的数据。
 - 在这样训练的博弈过程中, 提高两个模型的生成能力和判别能力。



Transformer




- Transformer是一种基于自注意力机制的深度学习模型，它在自然语言处理（NLP）领域引起了革命性的变化。
- Transformer模型的核心贡献在于它完全摒弃了传统的循环神经网络（RNN）结构，采用并行化的计算方式，显著提高了训练效率。同时，它通过自注意力机制有效地捕捉序列数据中的长距离依赖关系，增强了模型的表达能力。



2012 to Present: Deep Learning Explosion




CVPR Papers



*Publications at top Computer
Vision conference*

ML+AI arXiv papers per month



*arXiv papers per month
([source](#))*




2012 to Present: Deep Learning is Everywhere



Year 2010

NEC-UIUC




[Lin CVPR 2011]

Lion image by Swissfrog

Year 2012

SuperVision
(AlexNet)




[Krizhevsky NIPS 2012]

Figure copyright Alex Krizhevsky, Ilya Sutskever, and Geoffrey Hinton, 2012. Reproduced with permission.


Year 2014

GoogLeNet
(Inception)



[Szegedy arxiv 2014]

VGG



[Simonyan arxiv 2014]

Year 2015

MSRA(ResNet)



[He ICCV 2015]

Winners in ILSVRC



2012 to Present: Deep Learning is Everywhere



Image Classification




Image Retrieval




Alex Krizhevsky, Ilya Sutskever, and Geoffrey Hinton, 2012.



2012 to Present: Deep Learning is Everywhere



Object Detection



*Ren, He, Girshick, and Sun,
Faster R-CNN, NIPS 2015*

Image Segmentation




*Chen, ..., and Yuille,
DeepLab, TPAMI 2017*




2012 to Present: Deep Learning is Everywhere



Action Recognition



*Simonyan & Zisserman,
Two-Stream, NIPS 2014*



*Feichtenhofer, Fan, Malik, He,
SlowFast, ICCV 2019*




2012 to Present: Deep Learning is Everywhere



Pose Recognition (Toshev & Szegedy, DeepPose, CVPR 2014)



Playing Atari games (Mnih et al, DQN, Nature 2015)



Google DeepMind's Deep Q-learning

The algorithm will play Atari breakout.


The most important thing to know is that all the agent is given is sensory input (what you see on the screen) and it was ordered to maximize the score on the screen.

No domain knowledge is involved! This means that the algorithm doesn't know the concept of a ball or what the controls exactly do.

2012 to Present: Deep Learning is Everywhere



Medical Image Computing



Levy & Jain, NIPS Workshop 2016

Galaxy Classification



Dieleman et al, MNRAS 2014

Whale recognition, Kaggle Challenge



2012 to Present: Deep Learning is Everywhere



No errors



A white teddy bear sitting in the grass

Minor errors



A man in a baseball uniform throwing a ball

Somewhat related



A woman is holding a cat in her hand

Image Captioning

[Vinyals et al., 2015]
[Karpathy and Fei-Fei, 2015]



A man riding a wave on top of a surfboard



A cat sitting on a suitcase on the floor



A woman standing on a beach holding a surfboard

All images are CC0 Public domain:

<https://pixabay.com/en/luggage-antique-cat-1643010/>
<https://pixabay.com/en/teddy-plush-bears-cute-teddy-bear-1623436/>
<https://pixabay.com/en/surf-wave-summer-sport-litoral-1668716/>
<https://pixabay.com/en/woman-female-model-portrait-adult-983967/>
<https://pixabay.com/en/handstand-lake-meditation-496008/>
<https://pixabay.com/en/baseball-player-shortstop-infield-1045263/>

Captions generated by Justin Johnson using [NeuralTalk2](#)






2012 to Present: Deep Learning is Everywhere



Text-to-Image generation (Rombach et al., Stable Diffusion, CVPR

Text	<i>'A zombie in the style of Picasso'</i>	<i>'An image of an animal half mouse half octopus'</i>	<i>'An illustration of a slightly conscious neural network'</i>	<i>'A painting of a squirrel eating a burger'</i>
Prompt:				



2012 to Present: Deep Learning is Everywhere



Text-to-Video generation (OpenAI, Sora, Feb 15, 2024)


Text Prompt: A stylish woman walks down a Tokyo street filled with warm glowing neon and animated city signage. She wears a black leather jacket, a long red dress, and black boots, and carries a black purse. She wears sunglasses and red lipstick. She walks confidently and casually. The street is damp and reflective, creating a mirror effect of the colorful lights. Many pedestrians walk about.



2012 to Present: Deep Learning is Everywhere



General-purpose video encoder (Google Research, VideoPrism, Feb 20, 2024)



<https://arxiv.org/pdf/2402.13217.pdf>



2012 to Present: Deep Learning is Everywhere



General-purpose video encoder (Google Research,
VideoPrism, Feb 20, 2024)



<https://blog.research.google/2024/02/video-prism-foundational-visual-encoder.html>



2012 to Present: Deep Learning is Everywhere




大规模语言模型 (Large Language Models, LLM)，也称**大语言模型**或**大型语言模型**，是一种由包含**数百亿以上参数**的深度神经网络构建的语言模型，通常使用**自监督学习**方法通过**大量无标注文本**进行训练。

自2018年以来，Google、OpenAI、Meta、百度、华为等公司和研究机构都相继发布了包括BERT，GPT等在内多种模型，并在几乎所有自然语言处理任务中都表现出色。2019年大模型呈现爆发式的增长，特别是2022年11月ChatGPT (Chat Generative Pre-trained Transformer) 发布后，更是引起了全世界的广泛关注。**用户可以使用自然语言与系统交互，从而实现包括问答、分类、摘要、翻译、聊天等从理解到生成的各种任务。**大规模语言模型展现出了强大的对世界知识掌握和对语言的理解能力。

2012 to Present: Deep Learning is Everywhere



- 近年来规模超过100亿参数的大语言模型时间线
- 大语言模型的发展历程虽然只有短短不到五年，但是发展速度相当惊人，截止2023年6月，国内外有超过百种大模型相继发布



2012 to Present: Deep Learning is Everywhere



ChatGPT ▾

What can I help with?

Ask anything



Search

Reason



Create image

Code

Surprise me

Brainstorm

Analyze data

More

Welcome to Grok.
How can I help you today?

What do you want to know?



DeepSearch

Think

Grok 3 ▾



Research

Brainstorm

Analyze Data

Create images

<> Code



我是 DeepSeek, 很高兴见到你!

我可以帮你写代码、读文件、写作各种创意内容, 请把你的任务交给我吧~

给 DeepSeek 发送消息

深度思考 (R1)

联网搜索



进一步的阅读

- ❑ 各相关领域的最新进展可以参考其重要会议和期刊
 - 机器学习: JMLR, ICML, NeurIPS, ICLR
 - 计算机视觉: IJCV, CVPR, ICCV, ECCV
 - 多媒体: ACM MM, TIP, TMM
 - 人工智能: TPAMI, AAAI, IJCAI
 - 自然语言处理: ACL, EMNLP, NACAL