



《模式识别》

第十三章 广义弱监督学习

马锦华

<https://cse.sysu.edu.cn/teacher/MaJinhua>

SUN YAT-SEN University



声明：该PPT只供非商业使用，也不可视为任何出版物。由于历史原因，许多图片尚没有标注出处，如果你知道图片的出处，欢迎告诉我们 majh8@mail.sysu.edu.cn.



课程目录（暂定）

❑	第一章	课程简介与预备知识	6学时
❑	第二章	特征提取与表示	6学时
❑	第三章	主成分分析	3学时
❑	第四章	归一化、判别分析、人脸识别	3学时
❑	第五章	EM算法与聚类	3学时
❑	第六章	贝叶斯决策理论	3学时
❑	第七章	线性分类器与感知机	3学时
❑	第八章	支持向量机	3学时
❑	第九章	神经网络、正则项和优化方法	3学时
❑	第十章	卷积神经网络及经典框架	6学时
❑	第十一章	循环神经网络	2学时
❑	第十二章	Transformer	2学时
❑	第十三章	广义弱监督学习	2学时
❑	第十四章	开放世界模式识别	2学时

广义弱监督类型

- ❑ 不完全监督 (incomplete supervision)
 - 只有少量有标注数据, 有大量未标注数据
 - ❖ 主动学习、半监督学习、自监督学习等
- ❑ 不确切监督 (inexact supervision)
 - 监督信息不够精确, 仅有粗粒度的标签信息
 - 狭义弱监督学习
- ❑ 不准确监督 (inaccurate supervision)
 - 标签信息不总是ground-truth

概览

- ❑ 半监督学习
- ❑ 迁移学习
- ❑ 自监督学习
- ❑ 弱监督学习
- ❑ 主动学习

有监督学习

$$\mathbf{X} = \{(x_i, y_i)\}_{i=1}^n$$

$$x_i \in R^d \quad y_i \in \{+1, -1\}$$




寻找分类函数 $f(x)$

色泽	根	敲声	好瓜
青绿	蜷缩	浊响	是
乌黑	蜷缩	浊响	是
青绿	硬挺	清脆	否
乌黑	稍卷	沉闷	否

类标号

Positive



Negative

Decision boundary

在传统的分类学习中，每个数据样本都给定类别标签指导分类学习，因此称为有监督分类学习（supervised classification）



有监督学习的局限

收集数据样本容易，但获得样本类别标记相对困难

- 计算机辅助医学图像分析
- 垃圾邮件检测
- web网页推荐



获得样本类别标记需要人力、物力、财力



如何同时利用无标记样本？



半监督分类


半监督分类 (semi-supervised classification): 同时利用大量无标记样本和少量有标记样本进行分类学习, 以获得比仅利用少量有标记样本的有监督分类学习更好的分类性能

$$X_l = \{(x_i^l, y_i)\}_{i=1}^{n_l}$$



$$X_u = \{(x_i^u)\}_{i=1}^{n_u}, n_u \gg n_l$$

$$x_i \in R^d$$

$$y_i \in \{+1, -1\}$$



Labeled data *only*



Labeled and unlabeled data

综述论文或书籍:

- O. Chapelle et al. Semi-supervised learning. MIT Press Cambridge, 2006.
- X. Zhu and A. Goldberg. Introduction to semi-supervised learning. Morgan & Claypool Publishers, 2009.
- Z.-H. Zhou and M. Li. Semi-supervised learning by disagreement. Knowledge and Information Systems, 24(3):415–439, 2010.
- Z.-H. Zhou. Disagreement-based semi-supervised learning. Acta Automatica Sinica. Invited Survey. Nov. 2013.

学习方法

◆ 半监督分类方法可大致分为四大类：

- 生成式方法
- 大间隔半监督分类方法
- 基于图的半监督分类方法
- 基于差异性的方法

生成式方法

• 生成式 (generative) 方法

- 假设有标记和未标记数据由同一概率模型生成，以生成式模型作为分类模型，利用期望最大化 (Expectation-Maximization, EM) 算法估计模型参数以及样本属于每类的概率
- 不同方法的区别在于所采用的生成式模型不同，如混合高斯模型 (mixture Gaussian model)，朴素贝叶斯模型 (naïve Bayes model) 等

- Shahshahani, B. & Landgrebe, D. (1994). The effect of unlabeled samples in reducing the small sample size problem and mitigating the hughes phenomenon. *IEEE Transactions on Geoscience and Remote Sensing*, 32(5): 1087-1095.
- Nigam, K., McCallum, A. K., Thrun, S. & Mitchell, T. (2000). Text classification from labeled and unlabeled documents using EM. *Machine Learning*, 39(2):103-134.

生成式方法

- 假设样本由高斯混合模型生成, 且每个类别对应一个高斯混合成分:

$$p(\mathbf{x}) = \sum_{i=1}^k \alpha_i \cdot p(\mathbf{x} | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

其中, $\alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1$

$$p(\mathbf{x} | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) = \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)}$$

生成式方法

□ 由最大化后验概率可知：

$$f(\mathbf{x}) = \operatorname{argmax}_{j \in \mathcal{Y}} p(y = j | \mathbf{x})$$

$$= \operatorname{argmax}_{j \in \mathcal{Y}} \sum_{i=1}^k p(y = j, \Theta = i | \mathbf{x}) \quad p(y = j | \Theta = i)$$

$$= \operatorname{argmax}_{j \in \mathcal{Y}} \sum_{i=1}^k \boxed{p(y = j | \Theta = i, \mathbf{x})} \cdot p(\Theta = i | \mathbf{x})$$

$$p(\Theta = i | \mathbf{x}) = \frac{\alpha_i p(\mathbf{x} | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{i=1}^k \alpha_i p(\mathbf{x} | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}$$

生成式方法

- 假设样本独立同分布，且由同一个高斯混合模型生成，则对数似然函数是：

$$\ln p(D_l \cup D_u) = \sum_{(\mathbf{x}_j, y_j) \in D_l} \ln \left(\sum_{i=1}^k \alpha_i \cdot p(\mathbf{x}_j \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot p(y_j \mid \Theta = i, \mathbf{x}_j) \right) \\ + \sum_{\mathbf{x}_j \in D_u} \ln \left(\sum_{i=1}^k \alpha_i \cdot p(\mathbf{x}_j \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \right) .$$

生成式方法

- 高斯混合模型的参数估计可以采用EM算法求解，迭代更新式如下：
- E步：根据当前模型参数计算未标记样本属于各高斯混合成分的概率

$$\gamma_{ji} = \frac{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}$$

生成式方法



- M步：基于 γ_{ji} 更新模型参数

$$\mu_i = \frac{1}{\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} \mathbf{x}_j + \sum_{(\mathbf{x}_i, y_i) \in D_l \wedge y_j = i} \mathbf{x}_j \right)$$

$$\Sigma_i = \frac{1}{\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} (\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^T \right. \\ \left. + \sum_{(\mathbf{x}_i, y_i) \in D_l \wedge y_j = i} (\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^T \right)$$

$$\alpha_i = \frac{1}{m} (\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i)$$



生成式方法



混合高斯模型



生成式方法



- Xiaojin Zhu, Semi-supervised learning Tutorial, Univ. Wisconsin, Madison, ICML, 2007.


生成式方法

- ❑ 将上述过程中的高斯混合模型换成**混合专家模型**、**朴素贝叶斯模型**等即可推导出其他的生成式半监督学习算法
- ❑ 此类方法简单、易于实现, 在**有标记数据极少**的情形下往往比其他方法性能更好
- ❑ 然而, 此类方法有一个关键: **模型假设必须准确**, 即假设的生成式模型必须与真实数据分布吻合; 否则利用未标记数据反而会显著降低泛化性能

- F. Cozman and I. Cohen. Unlabeled data can degrade classification performance of generative classifiers. In Proceedings of The 15th International Florida Artificial Intelligence Society Conference, Pensacola, Florida, United States, 327-331, 2002
- T. Yang and C.E. Priebe. The Effect of Model Misspecification on Semisupervised Classification. IEEE Transactions on Pattern Analysis and Machine Intelligence, 33 (10): 2093 - 2103, 2011

大间隔半监督分类方法

- 最大化所有样本的类间间隔, 从而引导分类边界穿越数据分布的低密度区域
 - 直推式SVM (Transductive SVM, TSVM)、半监督SVM (Semi-Supervised Support Vector Machine, S3VM) 等



- Bennett, K.P., & Demiriz, A. (1999). Semi-supervised support vector machines. In Kearns, M. J., Solla, S. A. & Cohn, D. A. editors, *Advances in Neural Information Processing Systems 11*, MIT Press, Cambridge, MA. 368-374.
- Joachims, T. (1999). Transductive inference for text classification using support vector machines. In: *Proceedings of the 16th International Conference on Machine Learning*, Bled, Slovenia, 200-209.
- Yu-Feng Li, James T. Kwok, and Zhi-Hua Zhou. Semi-supervised learning using label mean. In: *Proceedings of the 26th International Conference on Machine Learning (ICML'09)*, Montreal, Canada, 2009, pp.633-640


大间隔半监督分类方法

SVM分类函数 $f(x) = w^T x + b$

优化目标


$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

$$\text{s.t. } y_i (w^T x_i + b) \geq 1 - \xi_i$$
$$\xi_i \geq 0$$



大间隔半监督分类方法

最大化有标记样本上的类间间隔



大间隔半监督分类方法

最大化有标记样本上的类间间隔




最大化所有样本上的类间间隔

优化目标

$$\min_{\substack{f \in \mathcal{H} \\ \mathbf{y} \in \mathcal{B}}} \frac{1}{2} \|f\|_{\mathcal{H}}^2 + C_1 \sum_{i=1}^l \ell(y_i, f(\mathbf{x}_i)) + C_2 \sum_{j=l+1}^{l+u} \ell(y_j, f(\mathbf{x}_j))$$

无标记样本
的分类损失



半监督S3VM [Joachims, ICML99]工作获得ICML'09十年最佳论文奖

大间隔半监督分类方法

半监督SVM同时寻找分类函数和无标记样本的类别标签，优化目标非凸



重点难点：如何设计出高效的优化求解策略？

- O. Chapelle, V. Sindhwani, and S. S. Keerthi. Optimization techniques for semi-supervised support vector machines. *Journal of Machine Learning Research*, 9:203–233, 2008
- O. Chapelle, M. Chi, and A. Zien. A continuation method for semi-supervised SVMs. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 185–192, Pittsburgh, PA, 2006
- O. Chapelle, V. Sindhwani, and S. S. Keerthi. Branch and bound for semi-supervised support vector machines. In B. Scholkopf, J. Platt, and T. Hoffman, editors, “*Advances in Neural Information Processing Systems 19*”, pages 217–224. MIT Press, Cambridge, MA, 2007
- Y.-F. Li, J.T. Kwok, and Z.-H. Zhou. Semi-supervised learning using label mean. In *Proceedings of the 26th International Conference on Machine Learning*, pages 633–640, Montreal, Canada, 2009



基于图的半监督分类方法

基于有标记和未标记数据间的相似性构建一个流形结构图，然后利用结构图和有标记样本的类别标签获取无标记样本的类别标签

—mincut、harmonic和流形正则化 (Manifold Regularization) 等

- X Zhu, Z Ghahramani, J Lafferty (2003). Semi-supervised learning using Gaussian fields and harmonic functions. *Twentieth International Conference on International Conference on Machine Learning*, Washington, DC, USA, 912-919
- Wang, F., & Zhang, C. (2006). Label propagation through linear neighborhoods. In: *Proceedings of the 23rd International Conference on Machine Learning*, Pittsburgh, PA, 985-992.
- Belkin, M., Niyogi, P., & Sindhwani, V. (2006). Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. *Journal of Machine Learning Research*, 7: 2399-2434.

基于图的半监督分类方法



- 在所有样本上构建一个流形结构图，图结点代表数据样本，边权刻画样本之间的相似性或距离
- 假设在图上相似的样本共享相同的类标签
- 推断无标记样本的类标签

基于图的半监督分类方法

最小化能量函数

$$\min \sum_{i \sim j} \underline{w_{ij}} (f(x_i) - f(x_j))^2$$

流形图边权

- 设置 $f(x_i)=y_i, i=1 \dots n_l, f(x_j)$ 为任意值, $j=1 \dots n_u$
- 重复更新 $f(x_j)$ 直至收敛

基于图的半监督分类方法[Zhu et al., ICML03]工作获得ICML'13十年最佳论文奖



流形结构图的构建, K近邻? 热核权?

- Yu-Feng Li, Shao-Bo Wang, Zhi-Hua Zhou. Graph quality judgement: A large margin expedition. In: Proceedings of the 25th International Joint Conference on Artificial Intelligence (IJCAI'16), New York, NY, 2016, pp.1725-1731

基于差异性的方法


利用两个或多个视图训练分类器，在学习过程中，各分类器挑选若干置信度高的无标记样本进行相互标记，然后更新分类模型

- Co-EM、 Tri-training等
- 为了使用此类方法，需能生成具有显著差异（分歧）、性能尚可的多个学习器，但当有标记样本很少、尤其是数据不具有多视图时，要做到这一点并不容易

- Nigam, K. & Ghani, R. (2000). Analyzing the effectiveness and applicability of co-training. In: *Proceedings of the 9th ACM International Conference on Information and Knowledge Management*, Mclean, VA, 86-93.
- Zhou, Z.-H., & Li, M. (2005). Tri-training: Exploiting unlabeled data using three classifiers. *IEEE Transactions on Knowledge and Data Engineering*, 17(11):1529-1541.



基于差异性的方法

co-training示意图



学习原理

- 半监督分类**利用无标记样本**帮助提升学习性能
 - 试图挖掘隐藏在无标记样本中的数据分布信息，并利用该信息指导分类；
 - 为挖掘数据分布信息，必须采用某种数据分布假设；
 - 最常用的数据分布假设为**聚类假设 (cluster assumption)**和**流形假设 (manifold assumption)**



学习原理

数据分布假设

□ 聚类假设

- 假定属于同一聚类的样本有较大可能共享相同的类标签
- **等价表述：**分类边界应穿越数据分布的低密度区域，从而使聚类内（高密度区域中）样本被划分在分类边界两侧，也被称为**低密度分割假设**（low-density separation assumption）

□ 流形假设

- 假定数据分布在低维流形上，流形结构可由无向图表示，图中结点代表样本，边权代表样本间相似性
- 在流形结构上相似的样本具有相似类标签

学习原理

- ❑ 大部分现有的半监督分类方法都直接或间接地利用了上述两种假设：
 - 生成式方法：直接采用聚类假设
 - 基于支持向量机的方法：直接采用低密度分割假设
 - 基于图的方法：直接采用流形假设
 - 基于差异性的方法：间接利用聚类或流形假设

半监督降维方法

线性降维问题的一般定义：给定一个在 R^n 中的数据集合 $x_1, \dots, x_m$ ，求一个变换矩阵 A 将这 m 个数据点映射到 R^l ($l \ll n$)中的点 $y_1, \dots, y_m$ ，使得 y_i 代表 x_i ，且 $y_i = A^T x_i$ 。

LPP算法（局部保留投影，Locality Preserving Projections）是一种经典的半监督线性降维方法，算法步骤分为三个部分。

半监督降维方法

(1) 构建邻接图。 x_i 与 x_j 很接近(close)时, 我们在这两个点之间放置一条边。有两种选择标准:

- (a) ϵ -邻居($\epsilon \in \mathbb{R}$). 在 $\mathbb{R}^n$ 空间的欧几里得范数的条件下, 当 $\|x_i - x_j\|^2 < \epsilon$ 时, 我们记作节点 i 和 j 被一条边相连。
 - ❖ 优点: 来源于几何学的方法, 相互间的关系是天然对称的。
 - ❖ 缺点: 经常导致图中只有很少的部分相连, 选择一个合适的 ϵ 很难。
- (b) n 最近邻($n \in \mathbb{R}$). 如果 i 是 j 的 k 近邻且 j 是 i 的 k 近邻, 那么我们就记作 i 和 j 被一条边相连。
 - ❖ 优点: 容易选择; 不会导致图不连通。
 - ❖ 缺点: 缺少几何学上的直观性。

(2) 选择权重。给边加权重也有两种方法:

- (a) 热核法($t \in \mathbb{R}$). 如果节点 i 和 j 相连, 那么
$$W_{ij} = e^{-\frac{\|x_i - x_j\|^2}{t}}$$
- (b) 简单法. i 与 j 相连, $W_{ij} = 1$, 否则, $W_{ij} = 0$

半监督降维方法

(3) 求以下问题的特征值与特征向量:

$$XLX^T \mathbf{a} = \lambda XD X^T \mathbf{a} \quad (1)$$

D 是一个对角矩阵, $D_{ii} = \sum_j W_{ij}$, $L = D - W$, 称为拉普拉斯矩阵。且令列向量 $\mathbf{a}_0, \dots, \mathbf{a}_{l-1}$ 是方程(1)的解向量, 这些向量按照特征值由小到大排列, 对应的特征值为 $\lambda_0 < \dots < \lambda_{l-1}$ 于是, 嵌入映射可以表示如下:

$$x_i \rightarrow y_i = A^T x_i, A = (\mathbf{a}_0, \mathbf{a}_1, \dots, \mathbf{a}_{l-1})$$

半监督降维方法





Figure 2: The handwritten digits ('0'-'9') are mapped into a 2-dimensional space. The left figure is a representation of the set of all images of digits using the Laplacian eigenmaps. The middle figure shows the results of LPP. The right figure shows the results of PCA. Each color corresponds to a digit.

研究挑战



有时，同时利用无标记样本进行半监督分类学习不会带来性能提升，甚至可能造成性能下降。—————不安全半监督分类 (unsafe semi-supervised classification)

研究挑战



如何实现**安全半监督分类学习**，使利用无标记样本不会造成性能的显著下降？

- Yu-Feng Li and Zhi-Hua Zhou. Improving semi-supervised support vector machines through unlabeled instances selection. In: Proceedings of the 25th AAAI Conference on Artificial Intelligence (AAAI'11), San Francisco, CA, 2011, pp.386-391.
- Yunyun Wang and Songcan Chen. Safety-Aware Semi-Supervised Classification. IEEE Trans. Neural Netw. Learning Syst. 24(11): 1763-1772 (2013)
- Yu-Feng Li and Zhi-Hua Zhou. Towards making unlabeled data never hurt. IEEE Transactions on Pattern Analysis and Machine Intelligence, 37(1):175-188, 2015

近期研究进展

❑ 经典方法：

- Mean Teacher [NeurIPS 2017]
- FixMatch [NeurIPS 2020]


❑ 任务延伸：

- 目标检测
- 语义分割

概览

- ❑ 半监督学习
- ❑ 迁移学习
- ❑ 自监督学习
- ❑ 弱监督学习
- ❑ 主动学习

迁移学习简介



迁移学习将会是引领下一次机器学习热潮的驱动力。——吴恩达,NIPS 2016

迁移学习简介

- 什么是迁移学习？

- **心理学角度**：人们利用之前的经验和知识进行推理和学习的 能力。
- **机器学习角度**：一个系统将别的相关领域中的知识应用到本应用中的学习模式。[DARPA]
- 举例：C++ → Java；骑自行车 → 骑摩托车
- 关键词：举一反三




- 迁移学习要解决的问题：

- 给定一个研究领域和任务，如何利用相似领域进行知识的迁移，从而达成目标？

迁移学习简介

- 为什么要进行迁移学习？
 - 数据的标签很难获取
 - 从头建立模型是复杂和耗时的


对已有知识的重用是必要的



迁移学习简介

- 迁移学习 vs 传统机器学习

	传统机器学习	迁移学习
数据分布	训练和测试数据同分布	训练和测试数据不需要同分布
数据标签	足够的数据标注	不需要足够的数据标注
建模	每个任务分别建模	可以重用之前的模型



迁移学习简介


- 迁移学习常用概念

- **Domain (域)**：由数据特征和特征分布组成，是学习的主体
 - Source domain (源域)：已有知识的域
 - Target domain (目标域)：要进行学习的域
- **Task (任务)**：由目标函数和学习结果组成，是学习的结果

- 迁移学习的形式化定义

- 条件：给定一个源域 $\mathcal{D}_S$ 和源域上的学习任务 $\mathcal{T}_S$, 目标域 $\mathcal{D}_T$ 和目标域上的学习任务 $\mathcal{T}_T$
- 目标：利用 $\mathcal{D}_S$ 和 $\mathcal{T}_S$ 学习在目标域上的预测函数 $f(\cdot)$ 。
- 限制条件： $\mathcal{D}_S \neq \mathcal{D}_T$ 或 $\mathcal{T}_S \neq \mathcal{T}_T$

迁移学习的应用领域



模式识别

计算机视觉



数据挖掘



机器学习

迁移学习

语音识别



统计学习



自然语言处理



领域自适应

- 领域自适应:

- domain adaptation; cross-domain learning
- 问题定义: 有标签的源域和无标签的目标域共享相同的特征和类别, 但是特征分布不同, 如何利用源域标定目标域

$$\mathcal{D}_S \neq \mathcal{D}_T: P_S(X) \neq P_T(X)$$



领域自适应

– 基于特征的迁移方法：

- Transfer component analysis [Pan, TKDE-11]
- Geodesic flow kernel [Duan, CVPR-12]
- Transfer kernel learning [Long, TKDE-15]
- TransEMDT [Zhao, IJCAI-11]

– 基于实例的迁移方法：


- Kernel mean matching [Huang, NIPS-06]
- Covariate Shift Adaptation [Sugiyama, JMLR-07]

– 基于模型的迁移方法：

- Adaptive SVM (ASVM) [Yang et al, ACM Multimedia-07]
- Multiple Convex Combination (MCC) [Schweikert, NIPS-09]
- Domain Adaptation Machine (DAM) [Duan, TNNLS-12]

领域自适应

- 迁移成分分析 (TCA, transfer component analysis) [Pan, TKDE-11]
 - 将源域和目标域变换到相同空间, 最小化它们的距离




领域自适应


• 迁移成分分析:

- 优化目标: $\min_{\varphi} \text{Dist}(\varphi(\mathbf{X}_S), \varphi(\mathbf{X}_T)) + \lambda \Omega(\varphi)$
s.t. constraints on $\varphi(\mathbf{X}_S)$ and $\varphi(\mathbf{X}_T)$
- Maximum mean discrepancy (MMD)


$$\text{Dist}(P(\mathbf{X}_S), P(\mathbf{X}_T)) = \left\| \frac{1}{n_S} \sum_{i=1}^{n_S} \Phi(x_{S_i}) - \frac{1}{n_T} \sum_{j=1}^{n_T} \Phi(x_{T_j}) \right\|_{\mathcal{H}}$$



Original feature space



PCA




TCA

领域自适应


• Covariate Shift Adaptation [Sugiyama, JMLR-07]

- 采用自然估计法估计源域和目标域的密度比例，然后进行实例权重的分配，最后迁移
- 优化目标：

$$\begin{aligned} & \underset{\{\alpha_\ell\}_{\ell=1}^b}{\text{maximize}} \left[\sum_{j=1}^{n_{te}} \log \left(\sum_{\ell=1}^b \alpha_\ell \varphi_\ell(x_j^{te}) \right) \right] \\ & \text{subject to } \sum_{i=1}^{n_{tr}} \sum_{\ell=1}^b \alpha_\ell \varphi_\ell(x_i^{tr}) = n_{tr} \text{ and } \alpha_1, \alpha_2, \dots, \alpha_b \geq 0. \end{aligned}$$



(a) When input dimension is changed



(b) When training sample size is changed

领域自适应

- Adaptive SVM (ASVM) [Yang et al, ACM Multimedia-07]
 - 使用SVM模型，在适配和原始模型之间学习“数据函数”，达到模型迁移效果
 - 优化目标：

$$\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t. } \xi_i \geq 0, \quad y_i \sum_{k=1}^M t_k f_k^a(\mathbf{x}_i) + y_i \mathbf{w}^T \phi(\mathbf{x}_i) \geq 1 - \xi_i$$

领域自适应

- 深度迁移学习
 - 利用深度神经网络的结构进行迁移学习
 - 神经网络学习非线性的特征表示
 - 层次性
 - 使得数据具有不可解释性
 - 表明在数据中具有某些不可变的成分，可以用来迁移
- 代表方法
 - Joint CNN [Tzeng, ICCV-15]
 - DANN [ICML-15, JMLR-16]
 - Deep Adaptation Network (DAN) [Long, ICML-15]
 - Joint Adaptation Networks [Long, ICML-17]

领域自适应


- Joint CNN [Tzeng, ICCV-15]
 - 针对有稀疏标记的目标域数据，用CNN同时优化域之间的距离和迁移学习任务的损失

$$\mathcal{L}(x_S, y_S, x_T, y_T, \theta_D; \theta_{\text{repr}}, \theta_C) =$$

$$\mathcal{L}_C(x_S, y_S, x_T, y_T; \theta_{\text{repr}}, \theta_C)$$


$$+ \lambda \mathcal{L}_{\text{conf}}(x_S, x_T, \theta_D; \theta_{\text{repr}})$$

$$+ \nu \mathcal{L}_{\text{soft}}(x_T, y_T; \theta_{\text{repr}}, \theta_C).$$



领域自适应


- Deep Adaptation Network (DAN) [Long, ICML-15]
 - 将CNN中与学习任务相关的隐藏层映射到再生核希尔伯特空间中，通过多核优化的方法最小化不同域之间的距离



领域自适应


• Joint Adaptation Networks [Long, ICML-17]

- 提出一种新的联合分布距离度量关系，利用这种关系泛化深度模型的迁移学习能力，从而适配不同领域的数据分布
- 基于AlexNet和GoogLeNet重新优化了网络结构



领域自适应

域对抗神经网络 (Domain-Adversarial Neural Networks, DANN) [ICML-15, JMLR-16]



领域自适应

□ 总结


- 通常假设源域和目标域的数据有相同的条件分布，或者在高维空间里有相同的条件分布
- 这个假设是有一定局限性的，无法衡量源域和目标域之间相似性，可能发生负迁移
- 任务延伸：语义分割、目标检测、动作识别等
- 设定拓展：开集、多源域、无源域、通用等

领域自适应

□ 从不同的角度放宽闭集领域自适应的假设



部分集领域自适应



开集领域自适应



通用领域自适应




源域标签集



目标域标签集

领域自适应




通用领域自适应

- 通用领域自适应的目的是对目标域上的共有进行正确判别，并将所有未知类进行识别。
- 其难点在于，除了领域自适应存在的域差异外，还额外引入了类差异。
- 现有的方法通过在域对抗训练学习域相关特征并进行对齐从而达到知识迁移的目的。
- 该设定下，域相关特征包含两部分，一部分是域差异相关的特征，另一部分是类差异相关的特征。

领域自适应

层次特征分解网络 (Hierarchical Feature Disentangling Network, HFDN)



Gao, Yuan, et al. "Hierarchical feature disentangling network for universal domain adaptation." Pattern Recognition 127 (2022): 108616.

概览

- ❑ 半监督学习
- ❑ 迁移学习
- ❑ 自监督学习
- ❑ 弱监督学习
- ❑ 主动学习


有监督 vs 自监督学习

- ❑ **有监督学习** – learning with **labeled data**
 - 机器学习的主要方式
 - 通过大规模数据集预训练模型，学习特征表示方法用于小规模目标任务
- ❑ **无监督学习** – learning with **unlabeled data**
 - 发现数据中的模式规律，例如聚类、概率估计、降维等
- ❑ **自监督学习** – representation learning with **unlabeled data**
 - 从unlabeled data中通过**代理任务**（pretext tasks）学习可泛化的**特征表示方法**
 - “自监督”表示创造**自己的监督信息** (i.e., without supervision, without labels)
 - 自监督学习是无监督学习的一种


自监督学习

□ 自监督学习例子

- **代理任务**: 训练一个模型来**预测图像的旋转角度**（我们可以从互联网上收集数百万张图像，不需要标记）




- **下游任务**: 使用迁移学习并微调从代理任务中学习到的模型，以很少的标记样本对图像进行**分类**



自监督学习

□ 自监督学习示意图

- 对于下游任务，使用经过训练的骨干网络，在小型标记数据集上微调深层参数



自监督学习

- ❑ Why 自监督学习?
 - 为每一个任务收集有标签数据需要昂贵的时间人力成本
 - 自监督学习可以充分利用大量无标签数据 (images, videos, text)
 - 自监督学习可能会使特征更好地泛化到下游任务
- ❑ 自监督学习的挑战
 - 针对具体问题，如何选择合适的pretext task?
 - 没有金标准比较学习到的特征表示
 - 需要选择合适的损失函数，因为没有像监督学习中的测试集准确性作为明确的学习目标

基于图像的方法

- ❑ 识别几何变换
 - 图像旋转
- ❑ 基于Patches的方法
 - 相对图像块位置, 图像拼图
- ❑ 生成式方法
 - 图像着色, 跨通道预测, 图像超分辨率, 上下文编码器, 掩膜自编码器 (MAE)
- ❑ 自动标签生成
 - 深度聚类, 合成图像
- ❑ 对比学习
 - 对比预测编码, SimCLR, MoCo

图像旋转

❑ 识别几何变换


- [Gidaris \(2018\) - Unsupervised Representation Learning by Predicting Image Rotations](#)

❑ 训练数据: 图像随机旋转90度的倍数


- 产生四种旋转图像: 0° , 90° , 180° , 270°

❑ 代理任务: 通过预测所旋转的角度预训练模型

- 4类别分类问题




Architecture for Geometric Transformation Recognition




图像旋转

- 通过预测旋转角度，所学习的模型需要理解图像中的物体位置和种类



相对图像块位置

- ❑ 基于相对图像块位置的图像上下文预测
 - [Dorsch \(2015\) Unsupervised Visual Representation Learning by Context Prediction](#)
- ❑ 训练数据: 图像中提取多个图像块 (patches)
- ❑ 代理任务: 通过预测patches之间的关系预训练模型
 - 例如, 预测所选择图像块的相对位置 (i.e., 图像块 # 7)
 - ❖ 对于中心图像块, 有 8 个可能的邻居图像块 (8 个可能的类别)




Features Label (1-8)

Center Patch Random neighbor

Bottom Center(7)




相对图像块位置

- 通过预测patches之间的相对位置，所学习的模型需要理解图像中的空间关系




图像拼图

- ❑ 在图像拼图中预测图像块的位置
 - [Noroozi \(2016\) Unsupervised Learning of Visual Representations by Solving Jigsaw Puzzles](#)
- ❑ 训练数据: 与前一方法类似, 图像中提取 9 个图像块 (patches)
- ❑ 代理任务: 预测所有 9 个图像块的位置
 - 该方法不是仅预测 2 个图像块的相对位置, 而是使用 3×3 图像块的网格并解决拼图游戏



图像块

- 所学习的模型需要理解物体的局部相对位置和形状



图像着色

❑ 图像着色


- [Zhang \(2016\) Colorful Image Colorization](#)

- ❑ 训练数据: 彩色和灰度图像对

- ❑ 代理任务: 预测灰度图像中物体的颜色

- 模型需要理解图像中的物体，并为它们涂上合适的颜色

- 右下方的图像: 模型通过学习知道，天是蓝的，云是白的，山是绿的




图像着色

□ 一些着色例子



图像着色

- 使用基于卷积的编码器-解码器架构
 - 真实彩色图像和预测彩色图像之间的损失用于训练




图像超分辨率

❑ 图像超分辨率

○ [Ledig \(2017\) Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network](#)


❑ 训练数据: 正常图像和下采样图像对

❑ 代理任务: 预测下采样低分辨率图像相应的高分辨率图像



图像超分辨率

- ❑ SRGAN (Super-Resolution GAN) 是 GAN 用来产生超分辨率图像的变种
 - **生成器** 中输入低分辨率图像，利用全卷积网络输出高分辨率图像
 - **判别器** 结合 L_2 损失和图像内容损失，区分真实和生成（假的）高分辨率图像
- ❖ **图像内容损失** 比较真实和预测图像的特征




上下文编码器

- ❑ **预测缺失的部分，也可以称为上下文编码器或图像修复**
 - [Pathak \(2016\) Context Encoders: Feature Learning by Inpainting](#)
- ❑ **训练数据**: 随机去除图像的某一区域
- ❑ **代理任务**: 填入图像中的**缺失部分**
 - 模型需要理解整个图像的内容，为缺失的部分生成合理的填充



上下文编码器

- 联合损失函数 $\mathcal{L} = \lambda_{\text{rec}}\mathcal{L}_{\text{rec}} + \lambda_{\text{gan}}\mathcal{L}_{\text{gan}}$ 可以更好地预测缺少部分




Input image



Encoder-decoder
with reconstruction
loss $\mathcal{L}_{\text{rec}}$




GAN with loss $\mathcal{L}_{\text{gan}}$



Joint loss
 $\mathcal{L} = \lambda_{\text{rec}}\mathcal{L}_{\text{rec}} +$
 $\lambda_{\text{gan}}\mathcal{L}_{\text{gan}}$

上下文编码器

- ❑ 损失函数对比的其他例子
 - 联合损失函数可产生更真实的图像




上下文编码器

- 删除的区域可以有不同形状
 - 随机块掩模和随机区域掩模优于中心区域掩膜

Central region



Random block




Random region




掩膜自编码器 (MAE)

- **预测缺失的部分，也可以称为上下文编码器或图像修复**
 - [He \(2022\) Masked Autoencoders Are Scalable Vision Learners](#)
- **训练数据**: 随机遮盖大量图像块 (e.g., 75%)
- **代理任务**: 可见图像块输入到编码器，与掩膜tokens一起重构图像
 - 基于视觉Transformer (ViT)，只需要小部分可见图像块，可较好地重构整个图像
 - 预训练后，丢弃解码器，对所有图像块使用解码器提取特征



掩膜自编码器 (MAE)


□ 掩膜图像 (左)、重构图像 (中)、原图 (右)



深度聚类


❑ 图像深度聚类

- [Caron \(2019\) Deep Clustering for Unsupervised Learning of Visual Features](#)
- ❑ **训练数据**: 基于内容特征的图像簇 (cluster)
 - 例如, 山 (簇)、寺庙 (簇)、等等
- ❑ **代理任务**: 预测图像属于哪一个**簇**





深度聚类

- 相应自监督学习架构称为**深度聚类**
 - 模型将每一个簇看作一个类别
 - 对每一张输入图像，输出簇的编号 (i.e., cluster label)
 - 使用 k -means 聚类图像特征
- 模型需要学习图像中的内容，以便将它们分配到相应的簇




合成图像

- ❑ **合成图像 (Synthetic imagery)**
 - [Ren \(2017\) Cross-Domain Self-supervised Multi-task Feature Learning using Synthetic Imagery](#)
- ❑ **训练数据**: 利用游戏引擎或真实图像生成合成图像
 - 游戏中的图形引擎可以生成逼真的合成图像
- ❑ **代理任务**: 根据预测深度、曲面法线和轮廓图, 预测输入图像是合成图像还是真实图像
 - 所学习到的特征对于下游分割和分类任务很有用




合成图像

- 真实和合成图像用于训练权重共享的卷积网络
 - 判别器根据曲面法线、深度和边缘区分真实图像和合成图像
 - 模型通过同时提升生成器和判别器，以对抗方式（如 GAN）训练





合成图像

- 所学习到的深度、曲面法线和轮廓图，以及合成图像中相应的真实值





对比预测编码

- ❑ **对比预测编码 (Contrastive Predictive Coding, CPC)**
 - [Van der Oord \(2018\) Representation Learning with Contrastive Predictive Coding](#)
- ❑ **训练数据**: 输入图像中的图像块
- ❑ **代理任务**: 使用对比学习按顺序预测图像块序列
 - 例如, 如何根据图像中先前 (过去) 图像块的编码信息来预测下一个 (未来) 图像块
- ❑ 可用于不同领域: 语音音频、图像、自然语言和强化学习




对比预测编码

- ❑ **对比学习** 是基于将相似的样本分组在一起
 - 例如, 将下面的图像聚类到相似图像组
- ❑ **噪声对比估计 (Noise-Contrastive Estimation, NCE)** 损失在对比学习中很常用
 - NCE损失最小化相似图像之间的距离 (正例), 并最大化不相似图像之间的距离 (负例)
 - 其他可能用到的损失, 如InfoNCE损失, 或对比交叉熵损失



SimCLR


- ❑ **SimCLR**, a **Simple** framework for **C**ontrastive **L**earning of **R**epresentations
 - [Chen \(2020\) A Simple Framework for Contrastive Learning of Visual Representations](#)
- ❑ SimCLR 是对比学习的经典方法之一, 与CPC类似
- ❑ 当时在自监督学习中取得SOTA结果, 甚至比ImageNet上有监督训练的ResNet-50有更高的Top-1准确率



SimCLR

方法介绍:

- 随机采样 **小批量** n 个输入样本 x , 使用两种不同的 **数据增强** 操作 t 和 t' , 得到 $2n$ 个样本 $\tilde{x}_i = t(x)$ and $\tilde{x}_j = t'(x)$
 - ❖ 数据增强包括: random crop, resize with random flip, color distortions, and Gaussian blur (数据增强是对比学习中的关键)
- 将 **基编码器** $f(\cdot)$ 应用到 $\tilde{x}_i$ 和 $\tilde{x}_j$ 得到编码表征 $h_i = f(\tilde{x}_i)$ 和 $h_j = f(\tilde{x}_j)$
- 将另一个 **预测头编码器** $g(\cdot)$ (one fully-connected layer) 应用到 h_i 和 h_j 得到编码表征 $z_i = g(h_i)$ 和 $z_j = g(h_j)$



SimCLR

- $\mathbf{z}_i$ 和 $\mathbf{z}_j$ 视为**正样本对**，余下的 $2(n-1)$ 个样本视为**负样本**，计算余弦相似度

$$\text{sim}(\mathbf{z}_i, \mathbf{z}_j) = \frac{\mathbf{z}_i^T \mathbf{z}_j}{\|\mathbf{z}_i\| \|\mathbf{z}_j\|}$$

- **对比预测任务**将给出的样本 $\tilde{\mathbf{x}}_i$ 识别为正对样本 $\tilde{\mathbf{x}}_j$
- 样本 $\tilde{\mathbf{x}}_i$ 和 $\tilde{\mathbf{x}}_j$ 的**NCE损失**计算如下:


$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2n} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}$$

- $\mathbf{1}_{[k \neq i]}$ 如果 $k \neq i$ 则值为1，否则为0, τ 是温度超参数 (temperature hyperparameter)
- 总损失 $\sum_{i,j} \mathcal{L}_{i,j}$ 对所有小批量中的正样本对 $\tilde{\mathbf{x}}_i$ and $\tilde{\mathbf{x}}_j$ 计算
- 下游任务中丢弃预测头 $g(\cdot)$ ，只使用编码表征 $\mathbf{h}_i$

数据增强示意图



(a) Original



(b) Crop and resize



(c) Crop, resize (and flip)



(d) Color distort. (drop)



(e) Color distort. (jitter)



(f) Rotate $\{90^\circ, 180^\circ, 270^\circ\}$



(g) Cutout



(h) Gaussian noise



(i) Gaussian blur



(j) Sobel filtering

SimCLR

- 10个图像数据集中的实验结果
 - SimCLR 在多数数据集中超过有监督训练方法

	Food	CIFAR10	CIFAR100	Birdsnap	SUN397	Cars	Aircraft	VOC2007	DTD	Pets	Caltech-101	Flowers
<i>Linear evaluation:</i>												
SimCLR (ours)	76.9	95.3	80.2	48.4	65.9	60.0	61.2	84.2	78.9	89.2	93.9	95.0
Supervised	75.2	95.7	81.2	56.4	64.9	68.8	63.8	83.8	78.7	92.3	94.1	94.2
<i>Fine-tuned:</i>												
SimCLR (ours)	89.4	98.6	89.0	78.2	68.1	92.1	87.0	86.6	77.8	92.1	94.1	97.6
Supervised	88.7	98.3	88.7	77.8	67.0	91.4	88.0	86.5	78.8	93.2	94.2	98.0
Random init	88.3	96.0	81.9	77.0	53.7	91.3	84.8	69.4	64.1	82.7	72.5	92.5

其他对比自监督学习方法

- 其他基于对比学习的自监督学习方法包括:
 - **Augmented Multiscale Deep InfoMax** or **AMDIM**
 - ❖ [Bachman \(2019\) Learning Representations by Maximizing Mutual Information Across Views](#)
 - **Momentum Contrast** or **MoCo**
 - ❖ [He \(2019\) Momentum Contrast for Unsupervised Visual Representation Learning](#)
 - **Bootstrap Your Own Latent** or **BYOL**
 - ❖ [Grill \(2020\) Bootstrap your own latent: A new approach to self-supervised Learning](#)
 - **Swapping Assignments between multiple Views of the same image** or **SwAV**
 - ❖ [Caron \(2020\) Unsupervised Learning of Visual Features by Contrasting Cluster Assignments](#)
 - **Yet Another DIM** or **YADIM**
 - ❖ [Falcon \(2020\) A Framework for Contrastive Self-Supervised Learning and Designing a New Approach](#)
 - **And more ...**

视频自监督学习


- ❑ 视频提供比图像更丰富的视觉信息
 - 视频帧之间的空间和时间信息的一致性使它们适合从没有标签的原始视频中学习
 - 视频帧顺序验证, 运动物体跟踪, 视频着色, 等等

视频帧顺序验证

- ❑ **Frame ordering** also known as **shuffle and learn**
 - [Misra \(2016\) Shuffle and Learn: Unsupervised Learning using Temporal Order Verification](#)
- ❑ **训练数据**: 运动物体的视频, 帧顺序已打乱
- ❑ **代理任务**: 预测帧的**时间顺序**是否正确
 - 帧顺序被打乱, 具有正确和打乱顺序的视频对用于训练模型
 - 模型需要学习物体类别, 并且需要学习物体位置在帧中的时间顺序




Prepare Pairs




视频帧顺序验证

- ❑ 模型使用权重共享的卷积网络
 - 输出是视频帧顺序是否正确的二分类



视频帧顺序验证

□ 示例



运动物体跟踪


Tracking moving objects

- Wang (2015) [Unsupervised Learning of Visual Representations using Videos](#)

- 训练数据: 运动物体的视频


- 代理任务: 预测具有帧与帧之间运动物体的图像块位置

- 基于SURF特征的光流 (optical flow) 用于匹配视频帧之间的特征点
- 训练卷积网络预测下一帧的图像块位置
- 模型通过最小化帧与帧之间到被跟踪图像块 (在隐空间中) 的距离来学习特征表示




视频着色

- ❑ **Video colorization** or **temporal coherence of color**
 - [Vondrick \(2018\) Tracking Emerges by Colorizing Videos](#)
- ❑ **训练数据**: 运动物体的彩色和灰度视频对
- ❑ **代理任务**: 预测**运动物体**在其他帧中的**颜色**
 - 所学习到的表征对于下游分割、目标跟踪和人体姿势估计任务很有用




视频着色

- 视频分割和人体骨架姿态预测的输入和预测输出




视频着色

- ❑ 目标是将颜色从彩色的参考帧复制到灰度的另一个目标帧
- ❑ 模型需要利用帧与帧之间物体的时间一致性，以便学习如何将颜色应用于灰度帧
 - 这包括跟踪不同帧中的相关像素
 - 参考帧和目标帧在时间上不应相差太远




视频着色

□ 视频着色例子





背景鲁棒性




Wang, Jinpeng, et al. "Removing the background by adding the background: Towards background robust self-supervised video representation learning." *CVPR*. 2021.

抑制静态视觉信息



Zhang, M., Wang, J. and Ma, A.J., 2022, June. Suppressing Static Visual Cues via Normalizing Flows for Self-Supervised Video Representation Learning. In *Proceedings of the AAAI Conference on Artificial Intelligence* (Vol. 36, No. 3, pp. 3300-3308).

通道混叠视频感知





Lin, Yiqi, et al. "Learning Spatio-temporal Representation by Channel Aliasing Video Perception." *Proceedings of the 29th ACM International Conference on Multimedia*. 2021.

概览

- ❑ 半监督学习
- ❑ 迁移学习
- ❑ 自监督学习
- ❑ 弱监督学习
- ❑ 主动学习

物体识别中不同层次的人工标注



{motorbike (图像
标签), person
(图像标签)}

{motorbike (点标签),
person (点标签)}

{motorbike (框标
签), person (框
标签)}

{motorbike (像素标签),
person (像素标签)}

1 sec
per class

2.4 sec
per instance

10 sec
per instance

78 sec
per instance

annotation time

Berman et al., What's the Point: Semantic Segmentation with Point Supervision, ECCV 16

弱监督标注信息


相对于测试时所需的输出，训练时粗粒度的（便宜的）标注

挑战 – 部分/整体

弱监督学习

部分 vs 整体

“The same features are only present in the (whole) target object instances”



Question: What is a person?

- a) Face
- b) Face + upper body
- c) Face + whole body ☺

挑战 - 共存

弱监督学习

上下文信息 vs 目标物体

"The same features are only present in the (whole) target object instances"



Question: What is a train?

- a) Rail
- b) Train + Rail
- c) Train ☺☺

挑战 - 共存

弱监督学习

多个 vs 单个

"The same features are only present in the (whole) target object instances"




Question: What is a sheep?


- a) 2 sheep
- b) 3 sheep + grass
- c) 1 sheep 😊

多实例学习 (Multiple-instance learning, MIL)

Positive bags



Negative bags



包 (bags) = 图像 (images)
实例 (instances) = 窗口
(windows)


弱监督目标检测 (Weakly supervised object detection, WSOD) :

- 找出真正的正实例
- 训练窗口分类器

MIL: [Dietterich 1997 AI]

MIL-WSOD: [Blaschko NIPS 10, Deselaers ECCV 10, Nguyen ICCV 09, Russakovsky ECCV 12, Siva ICCV 11, Siva ECCV 12]

Standard MIL pipeline



两步交替优化

- 重新训练模型
- 重新定位物体

挑战


- 对初始化敏感 (局部极小值)
- 对预测窗口过拟合

窗口空间

如何生成包?

滑动窗口

- >100k per image
- 密集
- 2D平移, 尺度, 宽高比 (4D空间)



[Chum CVPR 07, Nguyen ICCV 09, Pandey ICCV 11]

Object proposals

- Selective Search and Edge Boxes


[van de Sande ICCV 11, Dollar ECCV 14]

- ~2k per image
- WSOD中更常用

[Deselaers ECCV 10, Siva ICCV 11, Russakovsky ECCV 12, ...]



Standard MIL pipeline



初始化




简单策略:

- 整图

[Nguyen ICCV 09, Bilen BMVC 14]

- 整图减去边缘


[Pandey ICCV11, Russakovsky ECCV12]



[Song ICML 14] 构造一个图来查找初始框:


1. 相关的 (在很多正图像中出现)
2. 有判别能力的 (与负图像中的框不一样)
3. 互补的 (捕捉多种模式)

Standard MIL pipeline



重新定位

Standard max formulation



$$\arg \max_b A(x_b)$$

/ / /
 Proposal Appearance Features
 model

- 选取得分最高的窗口作为正例
- 每图只选一个正例？

重新训练

Hinge and cross-entropy loss

For positive images:

$$\max_b A(x_b) > \Delta \quad (\Delta: \text{margin}) \quad \text{or} \quad \log(\text{Softmax}(\max_b A(x_b)))$$

For negative images:

$$\max_b A(x_b) < -\Delta \quad \text{or} \quad \log(1 - \text{Softmax}(\max_b A(x_b)))$$

Difference to supervised object detection (eg Faster-RCNN)

- Only 1 positive instance is used in each positive image
- No negative instances from positive image

重新定位和重新训练

More robust optimization: Relaxing max operator

保险起见，使用多个proposals

重新训练

For positive images

$$\log \sigma_b \exp A(x_b^+) > \Delta$$

For negative images

$$\log \sigma_b \exp A(x_b^-) < -\Delta$$


- 对初始化较不敏感
- 在训练中利用多个正样本



Max



Soft-max



重新定位和重新训练

More robust optimization: Self-paced learning


- 受Curriculum Learning启发
[Bengio ICML 09]
- 开始使用易样本训练,
再加入难样本
- WSOD中容易程度度量:
 - 通过窗口最大得分置信度选择样本
[Kumar NIPS 10]
 - 允许更小的窗口来选择窗口空间
[Bilen IJCV 14, Shi ECCV 14]
 - 通过类内竞争选择样本
[Sangineto PAMI 17]



(d) iter 0



(e) iter 1



(f) iter 5

Image credit: [Bilen IJCV 14]




Image credit: [Sangineto PAMI 17]

重新定位和重新训练

More robust re-localization: Multifold MIL [Cinbis CVPR 14]

Problem: Detector overfits into the given proposal

Solution: Train using positive examples in all folds but k, and all negative examples




重新定位和重新训练

Pairwise similarity

Similarity between selected windows across positive images

- 😊 Less overfitting
- 😞 Expensive to optimize
- 😞 Ignores intra-class variation



重新定位和重新训练

Pairwise similarity



Sub-categories

Clustering via probabilistic latent Semantic Analysis (pLSA)


[Wang ECCV 14]

- ☺ Modeling intra-class variations
- ☹ Sensitive to number of clusters

Exemplars

Pick representative samples

- ☺ No need to set number of clusters




[Chum CVPR 07, Bilen CVPR 15]

Image credit: [Bilen CVPR 15]


重新定位和重新训练

Additional cues: context

- Background provides contextual cues for recognition
- [Russakovsky ECCV 12, Bilen CVPR 14, Kantorov ECCV 16]
- Better separation of foreground and background
 - Additive: select a ROI that is semantically compatible with its context
 - Contrastive: select a ROI that is outstanding from its context



[Russakovsky ECCV 12]



[Kantorov ECCV 16]

重新定位和重新训练

Additional cues: Objectness

Quantify how likely a window is to contain an object of *any* class


[Alexe CVPR 10, Uijlings IJCV 13, Zitnick&Dollar ECCV 14]

- Generates a small set of accurate object proposals
- Steers re-localization towards objects and away from background
- Pushes towards whole objects instead of sub-regions

$$\operatorname{argmax}_b \lambda A(x_b) + (1 - \lambda) \operatorname{Obj}(b)$$

Commonly used for weakly supervised object Localization





[Deselaers ECCV 10, Khan OAGMW 11, Siva ICCV 11, Guillaumin CVPR 12, Prest CVPR 12, Shapovalova ECCV 12, Shi BMVC 12, Tang CVPR 14, Wang ECCV 14, Jerripathula ECCV 16, Cinbis PAMI 16, Bilen CVPR 16]



重新定位和重新训练

Priors: Equivariance

The predicted output should be equivariant to image transformations




Before

After

重新定位和重新训练

Priors: Scale [Shi ECCV 16]

- Curriculum learning (bigger objects down to smaller ones)
- Weight object proposals according to estimated size
- Requires training a size estimator from a small set




重新定位和重新训练


Priors: Motion

1. extracts candidate spatio-temporal tubes based on motion segmentation
2. selects one tube per video jointly over all videos
3. uses objectness to reduce object candidates
4. applies a domain adaptation method to address the video/image gap

- ☺ Motion cues for object boundaries
- ☹ Noisy data




Standard MIL pipeline



端到端 WSOD

Weakly Supervised Deep Detection Network (WSDDN) [Bilen CVPR 16]

- Previous work uses CNN as black-box feature extractor
- First end-to-end WSOD method, finetunes a pre-trained deep network
- Uses RoI-Pooling [Girshick ICCV 15]
- Two stream architecture
 - Classification: Associates each region with a class score
 - Localization: Compares regions for each class



端到端 WSOD

WSDDN

- ☺ State-of-the-art results with VGG-F (~AlexNet) (62% of supervised)
- ☺ End-to-end learning + No custom deep learning layers
- ☹ Detects discriminative parts rather than whole object extent
- ☹ Groups multiple instances together

Limitations (compared to the supervised case, eg Faster RCNN):

- It does not leverage multiple positive instances in positive images
- It does not exploit negative instances in positive images
- It does not learn bounding box regression




结合实例分类

Online Instance Classifier Refinement (OICR) [Tang CVPR 17]

WSDDN learns to classify images based on implicit instance scoring


OICR learns to classify instances

- Initially uses WSDDN to set instance labels
- Iteratively refines them by using an instance classifier



结合实例分类

Proposal Cluster Learning (PCL) for WSOD [Tang PAMI 18]



Observation: There can be multiple positive instances in an image


OICR considers only the highest scoring proposal + surrounding ones as positives

PCL

- builds an undirected graph of top- ranking proposals
- iteratively selects vertices which have most connections to be the cluster centres

正则化具判别部分

Instance-Aware, Context-Focused, and Memory-Efficient WSOD [Ren CVPR 20]



- Builds on **WSDDN** and **OICR**
- Picks top p % of the highest scoring proposals and surrounding ones as positives
- Introduces ConcreteDropBlock: a data-driven and parametric drop-out to drop the most relevant regions
- Adversarial optimization


$$w^*, \theta^* = \arg \min_w \max_{\theta} \sum_I \mathcal{L}_{\text{img}}(w, \theta) + \mathcal{L}_{\text{roi}}(w, \theta)$$

WSOD 总结

- 由于部分/整体和共存问题，WSOD 是一个有歧义的病态问题
- WSOD 训练对初始化敏感并容易过拟合
- 取得了明显的进展，由于
 - 物性度量、region proposals
 - 结合先验知识和额外线索
 - 端到端学习
- 为了解决固有的二义性需要更好的物性度量和更强的额外线索


弱监督显著性检测

- 针对像素级图像标注问题，提出了一种多源弱监督视觉显著性检测模型，他们设计了一个分类网络（CNet）和一个标题生成网络（PNet），分别学习预测对象以及生成图像标题。



弱监督动作定位

- 作者提出了一种基于弱监督方法的时序行为检测，即不需要具体的行为动作的时间定位信息，只通过视频类别信息进行训练而得到人体动作行为间隔信息。




概览

- ❑ 半监督学习
- ❑ 迁移学习
- ❑ 自监督学习
- ❑ 弱监督学习
- ❑ 主动学习

主动学习

- 假设有一个oracle，比如人类专家，可以向专家查询所选未标注数据的真值标签，让专家为估计模型最有价值的数据点打上标签。



主动学习

□ 主动学习的模型如下:

- $A = (C, Q, S, L, U)$

- 其中 C 为一组或者一个分类器, L 是用于训练已标注的样本, Q 是查询函数, 用于从未标注样本池 U 中查询信息量大的信息, S 是督导者, 可以为 U 中样本标注正确的标签。


主动学习

- 主动学习算法主要分为两阶段:
 - 第一阶段为初始化阶段，随机从未标注样本 U 中选取小部分，由督导者 S 标注，为训练集建立初始分类器模型；
 - 第二阶段为循环查询阶段， S 从未标注样本集 U 中,按照某种查询标准 Q ，选取一定的未标注样本进行标注，并加到训练样本集 L 中,重新训练分类器，直至达到训练停止标准为止。

主动学习

- ❑ 查询函数 Q 的设计最常用的策略是：不确定性准则和差异性准则。
- 不确定性：信息熵是衡量信息量的概念，也是衡量不确定性的概念。信息熵越大，就代表不确定性越大，包含的信息量也就越丰富。所以，不确定性策略就是要想方设法地找出不确定性高的样本，因为这些样本所包含的丰富信息量，对我们训练模型来说就是有用的。
- 差异性：查询函数每次迭代中查询一个或者一批样本。我们当然希望各个样本提供的信息不重复不冗余，即样本之间具有一定的差异性。在每轮迭代抽取单个信息量最大的样本加入训练集的情况下，每一轮迭代中模型都被重新训练，以新获得的知识去参与对样本不确定性的评估可以有效地避免数据冗余。

主动学习例子



Zhou Z, Shin J, Zhang L, et al. Fine-Tuning Convolutional Neural Networks for Biomedical Image Analysis: Actively and Incrementally[C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2017:4761-4772.

主动学习例子

Algorithm 1: Active incremental fine-tuning method.

Input:

$\mathcal{U} = \{\mathcal{C}_i\}, i \in [1, n]$ [$\mathcal{U}$ contains n candidates]

$\mathcal{C}_i = \{x_i^j\}, j \in [1, m]$ [$\mathcal{C}_i$ has m patches]

$\mathcal{M}_0$: pre-trained CNN

b : batch size

α : patch selection ratio

Output:

$\mathcal{L}$: labeled candidates

$\mathcal{M}_t$: fine-tuned CNN model at Iteration t

Functions:

$p \leftarrow P(\mathcal{C}, \mathcal{M})$ {outputs of $\mathcal{M}$ given $\forall x \in \mathcal{C}$ }

$\mathcal{M}_t \leftarrow F(\mathcal{L}, \mathcal{M}_{t-1})$ {fine-tune $\mathcal{M}_{t-1}$ with $\mathcal{L}$ }

$a \leftarrow \text{mean}(p_i)$ [$a = \frac{1}{m} \sum_{j=1}^m p_i^j$]

Initialize:


$\mathcal{L} \leftarrow \emptyset, t \leftarrow 1$

$$R_i(j, l) = \begin{cases} \lambda_1 e_i^j & \text{if } j = l, \\ \lambda_2 d_i(j, l) & \text{otherwise} \end{cases}$$

```

1 repeat
2   for each  $\mathcal{C}_i \in \mathcal{U}$  do
3      $p_i \leftarrow P(\mathcal{C}_i, \mathcal{M}_{t-1})$ 
4     if  $\text{mean}(p_i) > 0.5$  then
5        $S'_i \leftarrow$  top  $\alpha$  percent of the patches of  $\mathcal{C}_i$ 
6     else
7        $S'_i \leftarrow$  bottom  $\alpha$  percent of the patches of  $\mathcal{C}_i$ 
8     end
9     Build matrix  $R_i$  using Eq. 3 for  $S'_i$ 
10  end
11  Sort  $\mathcal{U}$  according to the numerical sum of  $R_i$ 
12  Query labels for top  $b$  candidates, yielding  $\mathcal{Q}$ 
13   $\mathcal{L} \leftarrow \mathcal{L} \cup \mathcal{Q}; \mathcal{U} \leftarrow \mathcal{U} \setminus \mathcal{Q}$ 
14   $\mathcal{M}_t \leftarrow F(\mathcal{L}, \mathcal{M}_{t-1}); t \leftarrow t + 1$ 
15 until classification performance is satisfactory;
```

1 Get the prediction of unlabeled data.




2 Compute the average probabilistic prediction of all of its patches.

$$a_i = \frac{1}{m} \sum_{j=1}^m p_i^j = \frac{1}{21} \sum_{j=1}^{21} p_i^j = 0.4705 < 0.5$$

3 Select the top α percent patches when $a_i > 0.5$, otherwise bottom α .

(3)



4 Construct the score matrix using either entropy or diversity quota.

$$e_i = - \sum_{k=1}^{|Y|} \sum_{j=1}^{am} p_i^{j,k} \cdot \log p_i^{j,k} = - \sum_{k=1}^2 \sum_{j=1}^5 p_i^j \cdot \log p_i^j = 0.2440$$

$$d_i = \sum_{k=1}^{|Y|} \sum_{j=1}^{am} \sum_{l=1}^{am} (p_i^{j,k} - p_i^{l,k}) \cdot \log \frac{p_i^{j,k}}{p_i^{l,k}} = 0.2964$$

5 Query labels for top frames according to their quota value.

